

浅层时空流量补全中的显式本流观测读出

作者信息待填写

中文内部研究初稿 2026 年 9 月 17 日

摘要—浅层时空模型已经能够访问本流观测，额外引入局部读出是否值得，仍需匹配对照验证。本文研究完整历史监督下的稀疏网络流量离线补全，将一层 SPIN 时空上下文与本流前后最近真实观测的三统计量读出联合解码。通过独立训练 Context-only 和 Direct-only，在两套 WAN 上比较两条路径的使用价值。固定 50 槽窗口、20% 输入观测、三种缺失条件和两个配对初始化，采用 120 轮训练及预先固定的 40 轮低学习率诊断，并保留两个预算截面。160 轮预算下，组合相对 Context-only 的开发 NMAE 在 Abilene 和 GEANT 分别降低 1.64% 与 2.19%，相对 Direct-only 分别降低 2.21% 与 4.32%；两个种子和三个条件方向一致，末端轨迹也支持这一排序。相对 Context-only，批量 8 的每窗推理耗时分别增加 3.82% 与 3.47%，但组合明显慢于 Direct-only，且并非所有误差指标或观测支持分组都更好。这些结果支持显式局部读出在当前浅层骨架上的增量，不证明其引入新信息、优于所有现有方法或具有独立未见流量泛化优势。本文提供具有明确评价边界的内部方法初稿，公平外部确认仍需完成。

关键词—网络流量矩阵，离线补全，时空上下文，局部观测读出，路径对照

I. 引言与相关工作

网络流量矩阵描述节点之间的流量需求，缺失项恢复可为离线网络分析提供输入。在已有完整历史数据、当前窗口只能观测部分流量的条件下，模型既可利用相关流的时空上下文，也可直接利用本流邻近观测。前者能够学习跨流关联，后者提供距离明确的局部插值线索。二者在信息覆盖上并不互斥：时空模型本就可以访问本流观测，增加一条显式读出路径是否值得，必须通过匹配对照回答。

本文围绕一个问题展开：本流显式观测读出，能否改善浅层时空模型的精度与执行成本取舍？我们采用一层 SPIN 时空块，另行读取本流前后最近的真实观测，将两个方向的局部统计量与上下文查询拼接解码，记为 SPIN+Direct。Direct 提供的是受约束的读出方式，并不增加原窗口中不存在的信息，也不保证无损保留观测幅值。本轮不增加融合门控、新损失或额外记忆，而是通过分别从头训练的 Context-only 与 Direct-only，检验两条信息路径的使用价值。

时空与局部信息的结合已有基础。SRMF 结合流量的较大范围结构和局部时空约束，并讨论邻近观测修正 [1]；因此，本文不将全局与局部结合本身作为新概念。SPIN 通过掩蔽时空注意力从稀疏观测构建目标表示 [2]，同时处理本流时间关系与邻流关系。本文复用其一层编码块，研究额外显式局部读出在这一浅层骨架上的增量，不把 Context-only 称为官方 SPIN，也不把相对旧四层 SPIN 的速度变化全部归因于 Direct。

同任务的 TM-LLM 已发表于 ISCC 2025，采用对抗式预补全、任务嵌入与提示，并适配预训练语言模型 [3]。其训练依赖和模型规模路线与本文的小型、从头训练模型不同；这里比较研究定位，不借用其不同协议下的数值建立优劣结论。2026 年预印本 Utimac 则在局部窗口中估计流量的统计分布与稀疏偏差，通过块坐标下降补全并报告不确定

性区间，主要面向数据中心流量，附录包含 GÉANT[4]。本文只输出点估计，不提出新的概率模型或不确定性保证。

此前我们还考察过在 SPIN+Direct 上增加同步矩阵记忆的 Full 变体。该分支延续 delta-rule 残差更新思想 [5]，现作为历史扩展对照保留，不承担本轮的主要方法主张。本文通过共同数据、配对初始化、固定优化日程及实际推理测量，回答局部读出与上下文组合的有限问题。结果属于开发评价：同一范围参与检查点选择和研究决策，因而本文仍是一份具有明确证据边界的内部方法初稿。

II. 方法与匹配路径对照

A. 任务与一层时空上下文

设窗口 $X \in \mathbb{R}_{>0}^{T \times F}$ ， $T = 50$ ，掩码 $M_{ti} = 1$ 表示可见。任务是离线整窗补全，允许读取前后两侧观测。完整拟合段确定全局均值 μ 和总体标准差 σ （下限 10^{-8} ），以及每流自身和相关系数最高的至多八个正 Pearson 相关邻流的集合。全局方差由流内方差与流均值间方差合成，不采用逐流标准化。当前窗口的隐藏值不进入编码，标准化输入为

$$z_{ti} = \begin{cases} (X_{ti} - \mu)/\sigma, & M_{ti} = 1, \\ 0, & M_{ti} = 0. \end{cases} \quad (1)$$

实现先按掩码清除隐藏输入，不依赖该位置的真值。

槽位 $t/49$ 经可学习映射，与流身份嵌入及正弦位置编码构成 32 维 p_{ti} 。可见位置加入数值编码，经归一化和数值跳连后，由一层 32 维 SPIN 时空块得到 h_{ti} [2]。本流时间注意力屏蔽同刻对角项；空间注意力排除自身流，逐邻流在源时间维归一化后聚合。所有查询位置均保留，只有真实可见位置作为注意力源；空支持读出为零，并保留根节点跳连。由 h_{ti} 经带偏置仿射投影获得 128 维查询，分为四个 32 维块；每块 v 按 $v/\max(\|v\|_2, 10^{-6})$ 归一化，拼接记为 $q(h_{ti})$ 。整窗上下文和双向读取均不提供在线因果保证。

B. 双向本流观测直读

对目标 (t, i) ，从 $s \leq t$ 与 $s \geq t$ 的本流可见位置中，分别选距离最近的至多两个，记为 S_{ti}^- 和 S_{ti}^+ 。可见目标自身可进入两侧集合；待补全位置不会读取自身隐藏值。两方向共享带偏置的 $32 \rightarrow 16$ 仿射投影 ϕ_Q^D, ϕ_K^D ，评分为

$$\ell_{tis} = \frac{\phi_Q^D(p_{ti})^\top \phi_K^D(p_{si})}{\sqrt{16}} - \log(1 + |t - s|). \quad (2)$$




图 1. SPIN 与本流观测读出使用同一窗口的可见输入，两路通过查询和解码接口联合训练。Direct 从真实观测提取统计量，不读取 SPIN 的预测。本轮匹配对照分别独立训练删除一条信息路径的模型；同步记忆仅作为历史扩展参考。

在每个非空方向集合内作 softmax，得到 α_{tis}^r ，其中 $r \in \{\rightarrow, \leftarrow\}$ 。每方向仅提取三个统计量：

$$\begin{aligned} v_{ti}^r &= \sum_{s \in S_{ti}^r} \alpha_{tis}^r z_{si}, \\ \delta_{ti}^r &= \sum_{s \in S_{ti}^r} \alpha_{tis}^r |t - s| / 49, \\ a_{ti}^r &= \mathbb{I}[S_{ti}^r \neq \emptyset], \quad d_{ti}^r = A[v_{ti}^r; \delta_{ti}^r; a_{ti}^r], \end{aligned} \quad (3)$$

其中两方向共享的 $A \in \mathbb{R}^{128 \times 3}$ 无偏置，空支持时三个统计量及读出均为零。因此 $\text{rank}(A) \leq 3$ ：128 维是统计量的嵌入宽度，不意味着提取 128 个独立的局部特征。给定参数后，权重由位置、距离和可见支持决定，不由当前流量数值决定；数值经加权、投影和解码后输出，不能称为保证保幅的原值复制。

C. 解码与训练目标

组合模型将两向 Direct 读出和上下文查询拼接，由 $384 \rightarrow 128 \rightarrow 1$ 的 GELU 解码器 D 输出原量纲预测：

$$R_{ti} = \mu + \sigma D([d_{ti}^+; d_{ti}^-; q(h_{ti})]). \quad (4)$$

推理时对缺失位置作非负截断，并回填可见真值。所有保留模块联合训练，解码末层零初始化。对批次缺失位置集合 Ω ，使用未截断的原量纲 L1 损失

$$\mathcal{L} = \frac{\sum_{(b,t,i) \in \Omega} |R_{bti} - X_{bti}|}{C|\Omega|}, \quad C = \text{mean}|X_{\text{fit}}|. \quad (5)$$

观测回填和非负截断均不参与该损失。

D. 两个单路径对照及实现边界

Context-only 删除 Direct 的评分与投影参数，保留 SPIN、 $q(h)$ 和原解码器，输入变为 $[0; 0; q(h)]$ 。**Direct-only** 删除数值上下文编码器与 SPIN 聚合，保留位置编码、Direct 与解码器，并将查询改为 $q(p)$ ，即输入 $[d^+; d^-; q(p)]$ 。后者的目标流预测不接收其他流当前窗口的数值、掩码或图信息，但仍沿用共同的拟合期全局标准化。两者均独立训练，不是推理时临时关闭分支。

同一种子先按组合模型的完整顺序初始化，再删除停用模块，使共有参数初值逐位一致。这些对照检验整条信息路径的使用价值，不是等参数量或等有效容量比较。Context-only 首层有 $256 \times 128 = 32,768$ 个权重对应恒零输入，数据损失对其梯度为零，虽仍受 AdamW 权重衰减，

不能表达额外信息。Context-only 也不是官方 SPIN 的复现替代品。

实现方面，Direct 先计算同流完整 $T \times T$ 评分再掩蔽筛选，因此逻辑上读取至多两个观测不构成时间线性复杂度保证。SPIN 也沿用密集时间配对及内部节点分块；本文只报告当前实现的实测成本。历史 Full 另将两个方向的同步记忆读出分别与 d^r 相加，其 120 轮结果仅用于展示额外记忆的取舍，不与本轮 160 轮路径对照混作同预算结论。

III. 实验设置

A. 数据、监督与开发范围

使用 Abilene 公开 X01-X24 记录中的 144 条流 [6]，以及 ARI-LLM 固定发布版本中的 GEANT 处理快照，后者为 10,772 行、462 条流 [7]。GEANT 尚缺少已核实的原生时间戳和物理单位映射，故窗口与距离均以槽位描述。以零起始、左闭右开区间表示，Abilene 拟合段为 $[0, 33335)$ ，开发段为 $[33384, 37484)$ ；GEANT 对应 $[0, 7023)$ 和 $[7072, 8322)$ 。每套数据沿用 512 个固定拟合窗口，GEANT 拟合窗口存在重叠；开发窗长 50、步长 50，分别为 82 和 25 个。

选定拟合窗的完整真值用于监督，整个拟合段用于全局统计量和相关邻流图。20% 观测率指当前窗口的输入预算，并非历史训练始终只能接触 20% 真值。开发段用于逐轮检查点选择，也已参与研究选型；历史后续范围曾被项目使用。所有本文准确率结果据此标为开发评价，不宣称独立未见流量测试。

B. 固定观测预算与指标

三种缺失条件均保留总计 20% 的数值。均匀条件每流保留 10/50 个位置；不均匀条件随机一半流保留 4 个、另一半保留 16 个。共享缺口条件保持同样的逐流数量，在稀疏与稠密流中各取近半，为合计一半的流设置共同连续 10 槽缺口；并非所有流同刻完全失观测。未受影响流沿用不均匀条件的观测位置。这些条件始终提供本流观测支持，不能据此宣称覆盖整流完全失观测。

对每个条件合并全部开发窗的缺失位置 Ω ，计算

$$\begin{aligned} \text{NMAE} &= \frac{\sum_{\Omega} |\hat{x} - x|}{\sum_{\Omega} |x|}, \\ \text{NRMSE} &= \sqrt{\frac{\sum_{\Omega} (\hat{x} - x)^2}{\sum_{\Omega} x^2}}. \end{aligned} \quad (6)$$

三条件等权平均 NMAE 始终为主指标, NRMSE 为辅助指标。报告两个初始化的均值和样本标准差, 并保留逐种子、逐条件数值; 相关缺失元素、三个条件和训练轮次均不充当独立训练重复。

C. 匹配训练与顺序筛选

三个模型使用种子 41001、41002; 共有参数同种子初值相同。AdamW 采用批量 8、权重衰减 10^{-4} 、梯度范数上限 1, FP32 且关闭 TF32。窗口顺序、训练掩码和开发掩码的种子分别为 51001、61001、71001, 前两者按轮产生共同日程, 训练条件近似均衡。固定前 120 轮学习率 10^{-3} , 第 121–160 轮为 10^{-4} , 不早停、不搜索其他日程。

两个新增对照从头训练 160 轮; SPIN+Direct 从既有第 120 轮的末轮检查点接续, 完整恢复模型、AdamW 和随机状态, 不从已选最佳点重启。既有组合的早期训练和续训只计同一条轨迹; 本次也不把接续算作额外独立重复。该组合的前 120 轮来自历史开发过程, 因此共同日程不消除此前研究选型的影响。本次降学习率诊断在新增训练前固定, 160 轮预算完成不等于充分优化。保存 120 轮预算截面; 主结果从第 1–160 轮中选三条件平均 NMAE 严格改善的最早最佳点。

按预定顺序, 先完成 GEANT; 仅当组合在两个种子上均优于两个单路径, 且末 20 轮中位数方向支持这一比较, 才原样扩至 Abilene。这一规则用于路线筛选, 没有事后百分比门槛, 也不构成显著性检验。末 20 轮轨迹、支持边界及缺口内外分组仅用于解释, 不替换主指标。

D. 参考方法与完整推理成本

Linear 为逐流可见位置线性插值, 边界使用端点; 无观测时用该流的拟合均值。旧四层 SPIN、旧 Direct+Sync 及历史 Full 按原有预算与初始化记录作为参考, 不参与本轮匹配路径归因, 也不与新对照混合计算种子统计量。特别地, 浅层与旧四层网络的速度差异不能单独归因于 Direct。

成本在同一 NVIDIA H20 上逐模型测量, 采用各数据前 8 个拟合窗, 仅使用 seed41001 的 160 轮预算最佳检查点。含 SPIN 的两个模型内部节点分块上限为 32, Direct-only 不执行该分块; 每条件、每批量先热身 5 次, 再计时 15 次。完整推理包含输入传输、全流预测、输出回传、有限值检查、非负截断及观测回填, 不包含权重加载、拟合统计量/图准备及掩码生成。批量 1 报告三条件整批中位数的平均; 批量 8 再除以 8, 表示每窗摊销成本, 非单请求延迟。显存报告批量 8 各条件最大的 PyTorch 已分配量, 不等同整卡占用。Linear 单独测 CPU 上的插值与拼接, 额外输出检查在计时区间外, 且不显式执行非负截断; 因此其边界与设备均不同于神经模型, 不据此声称跨设备加速比。

IV. 结果与设计取舍

A. 两条路径在当前骨架上均有增量

表 I 报告两个预算截面的全部模型均值与种子标准差。先行 GEANT 比较中, 160 轮预算下 SPIN+Direct 的 NMAE 为 0.164810, 低于 Context-only 的 0.168494 与 Direct-only 的 0.172246, 分别改善 2.19% 与 4.32%。符合预定筛选规则后, 原样扩展至 Abilene, 对应数值为 0.161358、0.164053 和 0.165011, 分别改善 1.64% 与 2.21%。两个 WAN 在 120 轮截面也有相同排序。更具体地, 两个预算下, 两个种子

在三个条件中的 NMAE 均优于对应单路径。这些结果补上了当前骨架的路径使用价值证据, 但不能把具有不同查询和解码设计的所有浅层 SPIN 实现一并排除。

固定降学习率阶段之后, 三个模型的轨迹波动减小。对每个 WAN 的两个种子及两个控制模型, 共八个配对, 组合在第 141–160 轮的每个开发分数, 均低于相应单路径在全 160 轮中的最佳分数。因此, 本轮排序并不只由某一个孤立低点产生。这些是相关优化迭代的描述, 既不是额外训练重复, 也不是显著性证据; 统一日程同时增加了训练轮数, 不能将全部变化单独归因于降低学习率。完整逐轮曲线及逐种子、逐条件结果随复核材料保留。

B. 辅助指标与观测支持并非全面改善

160 轮预算下, 组合的条件平均 NRMSE 在两个 WAN 和两个种子上, 均低于对应的两个单路径模型。但 GEANT 相对 Direct-only 在不均匀和共享缺口条件的 NRMSE, 两个种子均略差; 均值改善主要得益于均匀条件。因此, 不能由条件平均值推导所有缺失模式均改善。

预定义支持分组进一步限定解释。GEANT 上, 组合相对 Context-only 在两侧都有本流观测的内部位置改善, 但不均匀与共享缺口条件的单侧边界 NMAE 均值分别为 0.220937 对 0.220250、0.218896 对 0.217341, 即存在小幅退步。在受影响流的共同缺口内, 三模型 NMAE 均值依次为 0.181171、0.183979 和 0.191145。这些分组与局部读出提供插值偏置的解释相容, 不证明 Direct 恢复了 SPIN 必然丢失的幅值, 也不构成新的主指标。

C. 增量成本与简单模型的取舍

表 II 显示, 相对 Context-only, 加入 Direct 仅增加 1,440 个名义参数, 批量 8 每窗耗时在 Abilene 和 GEANT 分别增加 3.82% 和 3.47%, 峰值已分配显存几乎不变。这一结论不能扩大到全部执行情形: 批量 1 延迟分别增加 16.45% 和 4.03%。同时, 组合相对 Direct-only 的批量 8 耗时分别为 11.79 和 16.45 倍。所以较低的 NMAE 并不意味着在吞吐受限系统中应一律承担上下文网络的成本。

历史 Linear 在相同开发流量与掩码上的 NMAE 分别为 0.171021 和 0.167739, 本轮组合相对它分别改善 5.65% 和 1.75%。Abilene 的 NRMSE 也改善 9.35%, 但 GEANT 的 NRMSE 仍恶化 0.42%。Linear 的 CPU 成本已补测, 并与 GPU 结果分别注明设备及计时边界, 不作跨设备加速比宣称。旧四层 SPIN 和旧 Direct+Sync 参考保留在完整结果中, 其深度、训练日程或独立重复数量不同, 不能据此完成公平外部方法优势证明。

D. 历史同步记忆对照的保留范围

表 I 同时保留原 120 轮 Full 结果。在该历史配对中, 增加同步记忆后, Abilene 的 NMAE 基本持平且种子方向相反, GEANT 平均 NMAE 恶化 1.41%; 条件平均 NRMSE 分别改善 0.86% 和 1.24%。历史同设备测量中, Full 的批量 8 摊销成本分别增加约 64% 和 62%。这些事实解释了本轮优先验证无记忆组合的选择, 也保留了记忆对平方误差的收益。本轮没有把 Full 延长至 160 轮, 因此不据新旧预算交叉比较宣称同步机制普遍无效。

表 1

路径对照的开发结果。三个条件等权、两个种子均值 $\pm$ 样本标准差；主指标 NMAE 越低越好。120/160 沿用同一轨迹，FULL 仅保留历史 120 轮结果。

数据	模型	NMAE (120)	NMAE (160)	NRMSE (120)	NRMSE (160)
Abilene	SPIN+Direct	0.162369 $\pm$ 0.001505	0.161358 $\pm$ 0.001169	0.219958 $\pm$ 0.000469	0.218900 $\pm$ 0.000975
Abilene	Context-only	0.165258 $\pm$ 0.000923	0.164053 $\pm$ 0.000697	0.230239 $\pm$ 0.004439	0.223081 $\pm$ 0.000826
Abilene	Direct-only	0.165769 $\pm$ 0.000155	0.165011 $\pm$ 0.000010	0.222988 $\pm$ 0.000329	0.221870 $\pm$ 0.000239
Abilene	Full (历史)	0.162431 $\pm$ 0.000771	—	0.218068 $\pm$ 0.000153	—
GEANT	SPIN+Direct	0.167071 $\pm$ 0.000856	0.164810 $\pm$ 0.000562	0.231189 $\pm$ 0.001893	0.229734 $\pm$ 0.001502
GEANT	Context-only	0.170361 $\pm$ 0.000259	0.168494 $\pm$ 0.001417	0.233606 $\pm$ 0.001640	0.232153 $\pm$ 0.001936
GEANT	Direct-only	0.174090 $\pm$ 0.004006	0.172246 $\pm$ 0.003507	0.232496 $\pm$ 0.002733	0.231098 $\pm$ 0.001937
GEANT	Full (历史)	0.169420 $\pm$ 0.001018	—	0.228322 $\pm$ 0.000202	—

表 II

同一 H20 的完整推理成本与 CPU Linear 参考。B8 为每窗摊销耗时；显示为 PyTorch 峰值 ALLOCATED MEMORY。计时边界见正文。

数据	模型	B1/ms	B8/ms	MiB
Abilene	SPIN+Direct	9.72	6.14	2896.9
Abilene	Context-only	8.35	5.92	2896.8
Abilene	Direct-only	3.07	0.52	378.1
Abilene	Linear (CPU)	0.98	1.03	—
GEANT	SPIN+Direct	22.53	19.00	2976.8
GEANT	Context-only	21.66	18.36	2976.7
GEANT	Direct-only	3.12	1.16	1140.6
GEANT	Linear (CPU)	3.25	3.28	—

V. 讨论与局限

路径增量与机制解释。匹配路径对照检验的是当前实现、拟合数据和优化预算下，显式本流读出与时空上下文组合是否值得使用。Direct 访问的真实观测本来就在 SPIN 可用的输入集合内，所以其增量不能解释为引入了此前不可获得的信息。三统计量读出提供一种局部插值偏置，但本轮没有分离这一偏置、有效容量和优化行为的作用。固定参数初始化、数据与日程提高了比较的可解释性，仍不能证明另一种经过合理设计的浅层 SPIN 解码器无法获得相同收益。

精度与成本的适用范围。相对 Context-only 增加 Direct 的成本，与在 Direct-only 上加入整个上下文网络的成本，是两个不同的工程问题。后者即使降低 NMAE，也不意味着应在所有吞吐或延迟约束下选用组合。不同误差指标和掩码子组还可能存在取舍；NRMSE 的变化不能未经分解就解释为峰值恢复能力。本轮没有修改融合权重、增加门控或扩展损失来追求有利排序。

评价与优化边界。开发段同时承担检查点选择和研究决策，两个 WAN 的历史后续范围也已被项目访问。因此，配对方向、末段曲线和大量缺失项均不恢复独立测试身份。两个种子的样本标准差只描述有限重复；训练轮次彼此相关，末 20 轮诊断不构成显著性检验。统一的 40 轮低学习率阶段只是一项预先固定的优化诊断，达到 160 轮不能证明各架构充分收敛；历史 Full 未参加该诊断，其结果不支持对同步记忆在其他配方下的普遍否定。

任务与复现边界。本研究依赖完整历史监督、固定 50 槽窗口和 20% 当前输入预算，每流始终有至少四个观测，未评价整流完全失观测或在线因果重建。GEANT 时间和流

轴到原始采集记录的映射尚需进一步核实，不能将槽位距离直接换算成某种网络时间尺度。新实验保留源文件、数据、初始状态、掩码与检查点校验值，但训练入口仍依赖本机历史注册资产；公开源码本身不构成独立复现完成。

投稿前仍需完成的确认。下一步应固定候选及检查点、落实可核验的评价来源，再与正常工作的 SPIN、Linear、旧 Direct+Sync 及一个相关的 SRMF 加邻近观测校正参考作有限比较。Context-only 不能替代其中的外部 SPIN 基线。若只能复用历史流量，应明确称为冻结后复核；新掩码检验缺失模式变化，不是新的流量样本。这些工作用于确认实际方法价值，不需要再次扩张融合模块或消融矩阵。

VI. 结论

本文在浅层 SPIN 骨架中加入本流双向真实观测的显式统计量读出，并以独立训练的两个单路径对照检验组合的使用价值。两套 WAN、两个初始化及固定日程下，组合在开发 NMAE 上具有方向一致的增量，相对 Context-only 的批量 8 推理附加成本较小，末段轨迹也支持排序。另一方面，组合明显慢于 Direct-only，部分辅助误差和单侧支持分组仍存在取舍。本轮据此支持保留 SPIN+Direct 作为后续确认的主候选，并将 Full 限定为历史误差与成本参考。该结论补强了组件证据，尚不替代公平外部方法比较、评价来源核验与独立可执行的复现路径。

参考文献

- [1] Y. Zhang, M. Roughan, W. Willinger, and L. Qiu, "Spatio-temporal compressive sensing and internet traffic matrices," in *Proceedings of the ACM SIGCOMM 2009 Conference on Data Communication*, 2009, pp. 267–278. [Online]. Available: <https://www.cs.utexas.edu/~yzhang/papers/sensing-sigc09.pdf>
- [2] I. Marisca, A. Cini, and C. Alippi, "Learning to reconstruct missing data from spatiotemporal graphs with sparse observations," in *Advances in Neural Information Processing Systems*, vol. 35, 2022, pp. 32 069–32 082. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2022/file/cf70320e93c08b39b1b29a348097a376-Paper-Conference.pdf
- [3] K. Jiang, F. Yan, Y. Qiao, M. Li, Y. Li, and M. Conti, "Network traffic matrix imputation via large language models," in *2025 IEEE Symposium on Computers and Communications (ISCC)*. IEEE, 2025, pp. 1–7. [Online]. Available: <https://research.tudelft.nl/en/publications/network-traffic-matrix-imputation-via-large-language-models/>
- [4] X. Liu, Z. Wang, G. Liu, X. Tian, and W. Wei, "Rethinking traffic matrix completion: Estimate the process, not the entries," arXiv preprint arXiv:2605.02225v1, 2026. [Online]. Available: <https://arxiv.org/abs/2605.02225v1>

- [5] S. Yang, B. Wang, Y. Zhang, Y. Shen, and Y. Kim, "Parallelizing linear transformers with the delta rule over sequence length," in *Advances in Neural Information Processing Systems*, vol. 37, 2024, pp. 115 491–115 522. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2024/hash/d13a3eae72366e61dfdc7eea82eeb685-Abstract-Conference.html
- [6] "Abilene traffic matrix data: Format documentation," traffic weeks X01–X24; accessed September 16, 2026. [Online]. Available: <https://www.cs.utexas.edu/~yzhang/research/AbileneTM/readme.txt>
- [7] "ARI-LLM: Source code and released datasets," GitHub repository, pinned commit 6a4f63656dbf; accessed September 16, 2026. [Online]. Available: https://github.com/shuzi1024/ARI-LLM/blob/6a4f63656dbf0964219c516ffd3e1e8fcf99ebd/datasets/net_traffic/GEANT/geant.csv