

CalibTM：极端时间稀疏下的轻量锚点保持流量矩阵校准补全

CalibTM: Lightweight Anchor-Preserving Calibration for Traffic Matrix Completion under Extreme Temporal Sparsity

中文版方法论文研究稿 · v3 · 2026-08-12

摘要


流量矩阵（Traffic Matrix, TM）历史档案可能因设备维护、采集服务中断或数据传输失败而不完整。本文研究一个刻意收窄的离线补全设置：在长度为 50 的时间窗口中，每条 OD flow 仅保留 3 个真实观测点。此时 canonical Linear 已由观测锚点确定一个零训练成本的可行骨架。我们考察一个具体问题：学习器能否不把缺失值参数化为无约束的自由预测，而只学习显式插值骨架上的局部有界校准，从而形成更轻量的 accuracy – efficiency operating point。

为此，我们提出 CalibTM：一个仅含 5,475 个参数的 observation-derived、scaffold-conditioned bounded calibrator。它只由真实观测构造 canonical Linear，再以共享小型网络产生尺度归一的内部点级与边界段级校准。输出在最后一步精确复制全部观测点，并保证缺失位置非负。CalibTM 以一次前向完成补全，不需要大型时空主干。

在 Abilene 和 GEANT 的 K=3 structured masks 上，CalibTM 相对参数量与初始化匹配的静态校准取得数据集等权的 1.0425% NMAE 改善，相对 Linear 改善 1.5187%。冻结方法在 SNDlib BRAIN 第三 WAN confirmation 上相对静态校准和 Linear 分别改善 1.1396% 和 3.2627%，三个 seed 与两类 structured mask 均同向。冻结 H800 与 CPU checked-pipeline 测量进一步表明，CalibTM 位于几乎零成本的 Linear 与大型 learned baselines 之间。实验支持的是一个场景限定的受约束校准 operating point，而不是“所有低自由度模型都优于自由重建”的普遍结论。

关键词：流量矩阵补全；极端稀疏；受约束学习；插值校准；网络测量

CalibTM：由真实锚点定义 scaffold，只学习区域化有界校准



该对比表达设计原则，不构成对所有自由重建方法的 matched 因果结论。

图 1 CalibTM 的主机制。真实观测先定义 canonical Linear；共享校准器根据 scaffold 与观测导出尺度，对内部位置和单侧边界段施加显式有界的修正，随后精确复制锚点并保证缺失预测非负。下方设计空间对比表示本文选择的 operating point，而非其优于所有自由重建方法的因果结论。

1 引言

流量矩阵描述一个时间段内源—目的节点对之间的流量，是容量规划、异常分析和流量工程的重要输入。完整获取所有 OD flow 的细粒度历史序列往往代价高昂；实际档案还可能受到设备升级、采集服务中断和数据传输失败的影响。因此，从少量可信观测恢复缺失位置一直是网络测量中的基本问题。

公开测量基础设施也表明“采集过程本身会留下空档”并非纯想象：RIPE Atlas 提供持续的 anchor full-mesh 测量及按时间下载结果的[官方接口](#)；RIPE RIS 提供[时间索引的 MRT 档案规范](#)，官方 [RRC18 维护通知](#) 则明确记录 collector sessions 将中断且 MRT files 不会生成。RIPE RIS 不提供 traffic-volume TM truth；本文只在方法冻结后的描述性 replay 中，把三次维护事件的实测 payload-availability shape 转移到已消费的 A/G TM 窗口。它仍是 semi-synthetic measured-mask transfer，不是 native TM outage accuracy；主评估场景仍应准确称为 extreme artificial temporal thinning stress setting。

近年来，TM 补全方法从低秩矩阵/张量优化发展到神经张量补全、Transformer、扩散模型以及 LLM。ARI-LLM [1] 通过 flow-level tokenization 和 coarse-to-fine 自回归推理建模动态 TM；ImputeFormer [2] 把低秩先验嵌入 Transformer；Diffusion-TM [3] 和 3DDPS-TME [4] 则利用生成式分布学习或 routing-conditioned posterior sampling。这些方法分别利用跨 flow、绝对时间、拓扑或路由中的一种或多种结构。与之互补，本文关心在信息极少且 canonical Linear 已较强时，受约束的局部学习是否构成值得保留的成本—精度选择。

我们聚焦 offline archive repair under extreme temporal thinning：一个完整窗口在修复时可被双向查看，但每条 flow 仅有 $K=3$ 个观测；模型不获得 topology、routing 或持久 flow identity，也不决定采样位置。canonical Linear 已经给出一个无需训练、严格通过观测锚点的结构先验。我们的核心问题是：

在同一组稀疏锚点下，围绕显式 Linear scaffold 学习尺度受限的局部校准，能否以很小的 learned-model 成本获得稳定增益？

CalibTM 将修正分解到内部区间和单侧边界，并通过 [tanh](#)、锚点差和观测尺度限制幅度；观测位置在最终一步逐位 hard-copy。它以一次前向的局部校准算子替换 ARI-LLM 的 Flow2Vec、LLM 和五阶段 rollout，但本文把这种替换视为一种设计选择，而非“约束模型普遍优于自由重建”的因果结论。

本文贡献有三点：

1. 提出一个 topology-free、anchor-preserving 的有界插值校准算子，把学习限制在 canonical Linear 邻域中的内部点级与边界段级形变。
2. 通过同参数、同初始化的 context-free calibrator（代码名 [static_zero](#)）隔离“向共享 MLP 暴露 scaffold-derived 通道”的增量，并用冻结 head intervention 与 bound diagnostics 定位实际起作用的校准路径。
3. 在 Abilene、GEANT 和冻结的 SNDlib BRAIN 第三 WAN confirmation 上报告多 seed/mask 证据，并联合分析时间块稳健性、冻结权重跨 WAN transfer、现代 stress comparators 与实测成本所形成的 operating point。

2 相关工作与方法边界

2.1 矩阵与张量补全

传统方法依赖低秩、周期性或张量结构。WTTC-TS [5] 通过时间切片和加权张量核范数处理连续缺失，在无需预训练的情况下追求较简单的优化形式；其后续工作 [6] 又结合 tensor nuclear norm-minus-Frobenius regularization 与 time slicing。NTC [7]、DATC [8] 和 PetTC [9] 分别借助神经张量交互、对抗学习和对比嵌入增强 TM 表示。此类方法通常把多个 flow 或多个时间片作为联合结构；CalibTM 则刻意不使用可识别的跨 flow 关系，只在单 flow 锚点定义的可行邻域内校准。它的目标不是取代低秩/周期方法在充分结构信息下的上限，而是提供一个信息边界更窄、成本更低的 operating point。

2.2 插值引导与约束式补全

线性、样条和核插值长期以来都是时间序列缺失处理的基本工具。经典 PCHIP [10] 通过局部斜率选择实现锚点精确和形状保持；近期 percentile slope-constrained Linear [11] 又从观测差分分布估计阈值，以逐步裁剪不合理斜率。LinAR [12] 则把 autoregressive variation 与 Linear interpolation 结合，在水文缺口内恢复局部波动并减轻端点跳变。这些工作说明 anchor preservation、bounded interpolation 和 Linear refinement 都不能单独作为新颖性。

学习式方法也早已利用插值或初始估计。最直接的非 TM 碰撞是 DCCN-SPF [13]：它以 Linear 表示 PM2.5 的总体趋势，再让因果卷积网络预测细节偏差，而非直接预测完整缺口。Interpolation-Prediction Networks [14] 用可学习核插值把稀疏不规则观测映射到参考时间点；PriSTI [15] 把插值条件编码为扩散先验；RDPI [16] 从确定性初值出发，以 residual 为扩散目标进行 refinement；ImputeINR [17] 则从稀疏观测学习连续隐式函数。

因此，CalibTM 的新颖性不建立在“首次使用 Linear prior”“首次学习插值偏差”或“小 MLP”上。本文的贡献限定于一个更窄的 TM operating point：在每条 flow 仅有三个锚点、不使用 flow identity/topology/routing 时，把 observation-only Linear 固定为显式 scaffold，只学习尺度归一、内部/边界分区的有界形变，并以最终 hard-copy 保证锚点精确；static_zero matched control 进一步隔离向 MLP 暴露样本条件通道的增量价值。这一定位强调特定受约束参数化及其在极端稀疏 TM 中的实证 operating point，而不把插值引导补全这一大类思想当作本文首创。

2.3 高容量时空与生成式补全

ImputeFormer [2] 将低秩投影与 Transformer 结合，以兼顾时空归纳偏置和表达力。Diffusion-TM [3] 使用扩散模型学习完整 TM 分布，并在极低已知比例下进行分析；3DDPS-TME [4] 将 TM 构造成三维张量，并通过 routing equations 引导扩散后验采样。它们分别依赖跨变量结构、完整分布或 routing matrix，和本文“不使用 topology/routing/flow identity”的输入边界不同。我们只对 ImputeFormer 做了一个 bounded official-architecture task adapter；Diffusion-TM 与 3DDPS-TME 在本文中属于相关工作，而非已经完成公平适配的数值基线。

2.4 LLM 与过程建模

ARI-LLM [1] 把一条长度为 T 的插值后 flow 经 Flow2Vec/LSTM 压成一个 token，再由 LLM 在 flow tokens 间建模，并通过五阶段 coarse-to-fine rollout 输出完整 TM；CalibTM 则省去这一主干，只保留局部确定性校准。Utimac [18] 从局部平稳窗口的生成过程出发，将 log-domain 流量分解为主统计成分和稀疏偏差，并进行共享参数推断与不确定性刻画。它展示了“先识别过程，再设计估计器”的更强问题驱动范式；其跨 flow covariance、概率假设和 uncertainty 目标也不同于本文。

2.5 网络测量场景

INT-MC [19] 从 in-band telemetry 的真实 overhead 与 path-selection 问题出发，并在可编程交换机原型中验证矩阵补全。它提醒我们，人工 K/T 比例不能直接等价于实际 telemetry 节省。本文只研究已有离线档案的缺失值修复，不控制观测路径，不声称 $K=3/T=50$ 意味着 94% 的线上开销下降。

3 问题定义

令一个窗口内的 TM 为 $X \in \mathbb{R}^{(F \times T)}$ ，其中 F 为 flow 数，T=50 为时间长度。二值矩阵 $M \in \{0,1\}^{(F \times T)}$ 表示观测位置；主设置要求每条 flow 恰有 K=3 个观测。输入为 $X_{\text{obs}} = M \odot X$ 与 M，目标是在 $\Omega_{\text{miss}} = \{(f,t): M_{ft}=0\}$ 上预测 X。

本文采用 offline smoothing 而非 forecasting：修复某个内部缺口时允许使用其左右两侧已经存在于档案中的观测。边界位置不存在包围目标的左右锚点对；canonical Linear 使用单侧最近锚点延拓，而 CalibTM 的校准仍条件于该 flow 全部可见观测导出的均值、标准差与局部尺度。模型输出 $\hat{X}$ 需要满足两个硬约束：

1. 锚点保持：对所有 $M_{ft}=1$ ， $\hat{X}_{ft}=X_{ft}$ ；
2. 非负性：对所有缺失位置， $\hat{X}_{ft} \geq 0$ 。

主指标为 ratio-of-sums NMAE：

$$\text{NMAE} = \frac{\sum_{(f,t) \in \Omega_{\text{miss}}} |\hat{X}_{ft} - X_{ft}|}{\sum_{(f,t) \in \Omega_{\text{miss}}} |X_{ft}|}.$$

所有正式方法比较共享相同窗口、mask 与 target 集合。Relative gain 定义为 $1 - \text{NMAE}(\text{method})/\text{NMAE}(\text{comparator})$ ，正值表示 method 更好。

3.1 场景边界

本文主实验的 K=3 masks 是人工 thinning，包括 random、internal block 和 two-burst；periodic polling 与 shared contiguous-outage 仅是具有 wall-clock 解释的 synthetic stress。它们不是 measured native TM missing trace。Abilene 为 5-minute bins，GEANT 为 15-minute bins，相同离散 mask 不代表相同物理时长。BRAIN 使用 1-minute bins，但其 OD demand 来自 link measurements 经 goals、path-flow LP 和取整反演，不是直接 OD collector。

4 CalibTM：锚点保持的有界插值校准

4.1 Observation-only canonical Linear

对目标位置 t ，若左右锚点 (t_L, x_L) 与 (t_R, x_R) 均存在，先构造

$$B_t = (1-r_t)x_L + r_tx_R, r_t = (t-t_L)/(t_R-t_L)。$$

边界缺口使用最近观测值延拓。所有涉及 Linear 的模型输入、prior feature 与 Linear baseline 共享同一纯函数；插值过程中不读取缺失真值。

4.2 归一化与条件输入

每条 flow 的均值和标准差只由当前观测计算；仅在整条 flow 无观测，或观测标准差低于 $1e-6$ 时使用训练集冻结 fallback。CalibTM 在归一化坐标中运行。对位置 (f, t) ，方法实际使用的条件信息定义为

$$z_{-}(f, t) = [B_{-}(f, t), x^{(obs)}_{-}(f, t), m_{-}(f, t), vbar_{-}f],$$

其中 B 为 canonical Linear， s_f 是在该 flow 逐观测标准化后重算的 `local_volatility`，而 $vbar_{-}f = s_f / (\max_g s_g + \epsilon)$ 是暴露给 MLP 的匿名窗口归一化特征。对正常的 $K \geq 2$ 非退化 flow， s_f 近似常数；它主要在退化或 fallback 情形下变化，不应被解释为丰富的原始局部波动信号。在真正缺失位置， $x^{(obs)} = m = 0$ ，因此逐位置变化的主要条件是 B 。

主文将共享校准器记为四维语义映射 $g_{-}\theta(z_{-}(f, t))$ ；冻结 checkpoint 的固定兼容接口与完整参数账本移至补充实现说明，它们不改变上述有效信息边界。 $\max_g s_g$ 对 flow permutation 不变，不含 flow identity、topology、routing 或逐点 cross-flow attention；但它使预测依赖当前 window 的 flow composition。因而 CalibTM 不能识别特定 flow 间关系，却也不是 strictly flow-local 或 flow-subset-consistent。

4.3 共享校准网络

共享网络 $g_{-}\theta(z_{-}(f, t))$ 由一个小型归一化 MLP 与三个标量输出头构成；冻结 checkpoint 共含 5,475 个参数，所有 flow 与时间位置共享。精确层宽、兼容布局与参数账本见补充实现说明。三个 head 产生：

- 插值比例修正 $\delta r_t = 0.25 \tanh(h_r)$ ；
- 内部偏移 $o_t = 0.10 \tanh(h_o)(|x_R - x_L| + s_f + \epsilon)$ ；
- 边界偏移 $e_t = 0.10 \tanh(h_e)s_f$ 。

内部缺口使用

$$r_t^{\wedge} \epsilon = d_L / (d_L + d_R + \epsilon), r_{\text{hat}}_t = \text{clip}(r_t^{\wedge} \epsilon + \delta r_t, 0, 1),$$

$$x_t^{\wedge} \text{int} = (1 - r_{\text{hat}}_t)x_L + r_{\text{hat}}_tx_R + o_t。$$

边界缺口使用 $x_t^{\wedge} \text{edge} = x_{\text{anchor}} + e_t$ 。对同一 flow 的同一侧边界段， B_t 、 $x^{(obs)}$ 、 m 与 flow-level 特征均不随位置变化，因此冻结 edge head 给出段内常量偏移；左右两侧可因锚点值不同而间接不同，但它不是随外推距离变化的 extrapolation curve。最后从归一化坐标恢复原尺度，对缺失预测做非负截断，并在最后一步以原始 bit-exact 值 hard-copy 所有观测。

这套参数化限制了归一化坐标中的修正幅度，但内部 offset 仍允许有限越界，因此它是 bounded calibration around Linear，而非严格凸包插值。恢复原坐标时乘回由当前观测计算的标准差，原始单位下的尺度适配主要来自这一步，而非 s_f 提供了丰富的 volatility 信号。冻结消融显示 δr 没有可测附加价值；本文保留它以忠实报告已冻结模型，但方法主张与主图聚焦于真正贡献收益的 internal/edge offsets。

命题 1 (锚点保持与有界形变)。对 $\sigma_f > 0$ 且原始观测锚点非负的有效输入，令 $y_L, y_R, B_t^{\wedge}(n), x_{\text{hat}}^{\wedge}(n)$ 分别表示归一化坐标中的左/右锚点、canonical Linear 和最终输出。对内部缺失令 $D_t = d_L + d_R$ 、 $\Delta_t = |y_R - y_L|$ 与 $\eta_t = |r_t^{\wedge} \epsilon - r_t| = d_L \epsilon / [D_t(D_t + \epsilon)]$ 。对本文 K3 设置，冻结参数化保证

$$|x_{\text{hat}}^{\wedge}(n) - B_t^{\wedge}(n)| \leq (\beta_r + \eta_t) \Delta_t + \beta_o(\Delta_t + s_f + \epsilon), \eta_t < 5 \times 10^{-7}；$$

对单侧边界缺失保证 $|x_{\text{hat}}^{\wedge}(n) - y_{\text{anchor}}| \leq \beta_e s_f$ ，其中 $\beta_r = 0.25$ 、 $\beta_o = \beta_e = 0.10$ 。恢复原量纲后，上述右端统一乘以观测定义的 σ_f ；同时 $M_{-}(f, t) = 1 \Rightarrow X_{\text{hat}}(f, t) = X_{-}(f, t)$ ，且所有缺失输出非负。

证明. $|\tanh(\cdot)| \leq 1$ 给出三个 head 的幅度界, $[0,1]$ 投影不扩张距离, 三角不等式即得两个界。反标准化后的边界锚点与内部 Linear scaffold 分别是非负观测值及其凸组合, 因而最终 $\Pi_{[0,+\infty)}$ 同样非扩张; hard-copy 则直接给出锚点精确性。 $\square$

4.4 训练

冻结目标为 $L=0.5 L_{K3} + 0.5 L_{K2\text{-middle-drop}}$ 。K2 由 K3 三个排序锚点中删除中间点产生, 因此 K2 是训练覆盖条件, 不能称 unseen-K。每个 checkpoint 训练 20 epochs、320 次 AdamW optimizer updates, 并按 source-dev NMAE 选择最早达到最小值的 epoch。

4.5 为什么需要 matched context-free control

Context-Free Calibrator (代码名 `static_zero`) 与 CalibTM 具有相同 5,475 参数、相同初始化、训练预算和有界外层公式, 但共享网络接收的语义条件向量被代数置零。因此, 共享 trunk 与 heads 只能学习全局固定系数; 这些系数仍作用于同一个由样本锚点、归一化锚点差、`s_f` 与最终观测标准差缩放的外层约束公式。因而 CalibTM 相对该 control 的收益仅识别向 MLP 暴露注册 scaffold-derived 通道的增量价值, 而非“增加一个 MLP”本身, 也不是“完全去除所有样本条件”的对照。它不能单独识别 boundedness、Linear scaffold 或区域分解的因果必要性。精确兼容布局与参数账本见补充实现说明。早期 single-seed source-dev prototype probe 显示 `blinear_only` 已解释大部分输入通道增量; local-volatility 的独立增量很小。该 probe 不是三 seed final-gate 消融, 本文因而只用它约束机制措辞, 不把 rich geometry 或 volatility 解释为核心发现。

5 实验设计

5.1 数据与证据角色

数据集	规模/时间粒度	主角色	关键限制
Abilene	144 flows ; 5-min bins	development 后的 historical final gate	人工 K3 ; 已消费证据
GEANT [20]	462 flows ; 15-min bins	development 后的 historical final gate	人工 K3 ; 已消费证据
SNDlib BRAIN [21]	161 nodes ; 14,311 directed pairs ; 1-min	冻结后的第三 WAN effect confirmation (Linear/Context-Free)	LP-inverted OD ; transductive schema ; 28 windows

BRAIN 的 fit/source-dev/confirmation 分别含 136/28/28 个不跨 gap 的 T=50 windows。其 confirmation payload 只在三 seed、两方法的 checkpoint registry 冻结后打开。

5.2 Baselines

我们报告 canonical Linear、同参数 `static_zero`、PCHIP、原 INFOCOM 工作的 metric-matched ARI reimplementation, 以及 ImputeFormer 官方架构的 bounded task adapter。注册 PCHIP 在内部区间使用标准 shape-preserving cubic slopes, 边界则按 first/last anchor 做 nearest-value extension, 随后执行非负截断与观测 hard projection; 它不是 SciPy 默认边界外推。ARI 与 ImputeFormer 的比较只在 A/G exact historical P0 上完成; BRAIN 没有这两个方法的结果。ImputeFormer 可使用 flow identity、cross-flow attention 和绝对时间, 信息类强于 CalibTM, 因此本文把它定位为 modern architecture stress comparator, 而不是信息匹配的机制 control 或跨网络 SOTA 排名依据。

5.3 统计与证据分层

A/G 主结果在 dataset $\times$ seed 内汇总 internal block 与 two-burst, 再按 seed 和 dataset 等权。BRAIN 先在 seed 内汇总两类 structured masks, 再对 seeds 7/8/9 等权。注册裁决保留原 paired bootstrap; 另做 reviewer-facing 只读敏感性分析: 固定三个 seed 等权, 仅重采物理时间窗口/连续块, 且每次 draw 跨 methods、masks 和 seeds 共享。flow、target、mask 与 seed 都不被当作独立现实样本。CalibTM 是在 A/G development 中通过 matched controls 选出的 operating point, 因此 A/G 属于开发后的 historical evidence; BRAIN 是模型与 checkpoint 冻结后的新增 WAN confirmation。head/bound diagnostics、时间块敏感性、场景压力、六方向 frozen transfer 与 RIS measured-mask replay 均为 post-gate descriptive, 不改变原 verdict, 也不与 formal evidence 合并成 pooled CI。

6 结果

6.1 三 WAN : Linear、context-free 与 scaffold-conditioned calibration

数据/证据	CalibTM NMAE	Context-Free	Linear	Gain vs context-free	Gain vs Linear
Abilene K3 structured	0.235979	0.239188	0.240525	+1.3413%	+1.8900%
GEANT K3 structured	0.219307	0.220950	0.221852	+0.7437%	+1.1474%
A/G dataset-equal	0.227643	0.230069	0.231189	+1.0425% [0.9175,1.1548]	+1.5187% [1.3316,1.6709]
BRAIN frozen confirmation	0.897916	0.908268	0.928203	+1.1396% [1.0511,1.2272]	+3.2627% [3.1243,3.3682]

A/G 的四个 structured dataset $\times$ mask cells 和三个 seed headline 均为正；但 792 个窗口级比较中有 48 个为负，因此不能声称逐窗口获胜。其 absolute Δ NMAE 相对 Context-Free/Linear 分别为 +0.00243/+0.00355；固定 seed、共享物理 window draw 的约 1 天 block 95% CI 分别为 [+0.8955%,+1.1930%] 与 [+1.3551%,+1.6881%]，约 2 天 block 仍全部为正。BRAIN 的 absolute Δ NMAE 为 +0.01035/+0.03029，28/28 物理窗口方向为正，中位 gain 为 +1.1533%/+3.1530%；但 confirmation 仅覆盖约一天、只有两个 UTC start-day clusters，不能声称已经控制日级或周级自相关。

表中的 A/G dataset-equal NMAE 是两个 seed-equal dataset NMAE 的算术平均，而正式 relative gain 是先在配对单元内计算、再按 seed/dataset 等权的 effect；因此不能用显示到六位小数的平均 NMAE 反推置信区间。传统 PCHIP 在同一 structured 协议中比 Linear 差 1.0900%，CalibTM 相对 PCHIP 改善 2.5800%，故它不是本设置中的 strongest baseline。

Structured NMAE 相对改善 (%)




图 2 Scaffold-conditioned calibration 相对 matched context-free control 与 canonical Linear 的 structured effect。A/G 为 historical evidence，BRAIN 为冻结后的第三 WAN confirmation；该图不表示 CalibTM 在三个 WAN 上均优于所有 learned methods。

6.2 大型 learned stress comparators 的网络异质性

Dataset	Linear	Context-Free	CalibTM	ARI metric-matched	ImputeFormer adapter
Abilene all masks	0.237557	0.236011	0.232858	0.230258	0.222715
GEANT all masks	0.217642	0.216573	0.215160	0.227781	0.312429
Dataset-equal	0.227600	0.226292	0.224009	0.229020	0.267572

CalibTM 相对 ARI 的 all-mask dataset-equal gain 为 +2.19%，95% CI [1.452,2.980]，但 Abilene 为 -1.129%、GEANT 为 +5.541%。ImputeFormer 相对 CalibTM 在 Abilene 为 +4.351%，在 GEANT 为 -45.211%。这种大幅反转使 per-dataset 结果比 pooled 排名更重要，也提示 bounded adapter 在 GEANT 上可能存在适配局限。本文据此将两者用于刻画 dataset-sensitive accuracy – cost tradeoff，而不据其宣称稳定领先。

6.3 可测收益集中于区域化 bounded offsets

冻结 checkpoint 的 inference-only single-head-zero intervention 得到：

模型 head	合法 target	Full over ablated	95% CI	结论
delta_r_head	internal	-0.00377%	[-0.02648,+0.02383]	无可测附加价值
internal_offset_head	internal	+2.49701%	[+2.04227,+2.93543]	内部收益主要来源
edge_offset_head	edge	+1.12546%	[+1.01446,+1.23407]	边界收益来源

两个 offset 作用于不同区域，单头效应不能相加为严格 decomposition。冻结 checkpoint 的 intervention 表明插值比例修正没有可测附加价值，而内部和边界 offset 分别解释对应区域的主要收益。该分析发生在模型身份冻结之后，因此本文忠实报告原三头 checkpoint；coordinate warp 不作为核心贡献。

冻结 replay 还显示：delta_r 平均只占允许半径的 1.67%/3.25%（A/G），且 r_hat 从未 clip；internal/edge offset occupancy 为 59.51%/64.57% 与 92.52%/82.48%，非负投影前的负预测比例为 2.19%/9.64%。bounds 与 projection 在当前实现中数值上活跃，但这不是 bounded 相对 unbounded/direct predictor 的 matched 必要性证明。

6.4 Measured-availability shape replay

三次 RIPE RIS collector maintenance 的 5-minute payload availability 在 outcome 前固定为 onset/recovery windows，再转移到已消费的 A/G TM。CalibTM 相对 Linear 为正 36/36、相对 Context-Free 为正 35/36；唯一反向是 GEANT – RRC12 onset – seed 1 的 -0.0813%。RRC18/RRC15 同形，因此六个 event-phase 仅有四种 unique masks；RRC12 原样保留 42 observed/8 missing。真实的只有 control-plane availability shape，TM values 仍来自 A/G；这不是 native TM outage、第三 WAN 或 confirmation，GEANT 也只保留 ordinal shape。

6.5 Frozen-weight cross-WAN transfer（描述性）

一项全方向 post-gate replay 保持模型权重不变，只应用 target-frozen observation-only preprocessing。六个 structured source→target 方向相对 source Context-Free 的 gain 为 +0.5677% 至 +1.4240%，相对 target Linear 为 +0.9966% 至 +2.7148%；54/54 完整因素均正。三个 target cohorts 已消费，且 BRAIN 的 fit-std fallback 涉及约 4.63% missing-truth mass，因此这是 descriptive frozen-weight transfer，不是 independent test 或 statistic-free universal zero-shot。

6.6 Accuracy – efficiency operating point

CalibTM 有 5,475 个 total/trainable parameters，主 checkpoint 为 27,202 bytes；metric-matched ARI 有 84,784,178 个 total parameters、32,012,594 个 trainable parameters，主 checkpoint 为 354,505,976 bytes。参数与 checkpoint 比分别为 15,485.7× 和 13,032.3×，两者不能混为同一压缩指标。

在单张 H800、BF16、seed-1 synthetic shape、batch=8 的冻结 Python pipeline 中：

Dataset	Linear	Context-Free	CalibTM	ARI	ImputeFormer
Abilene latency ms	0.340	2.867	3.171	37.372	5.836
Abilene peak MiB	4.835	55.413	55.413	548.876	171.361
GEANT latency ms	0.351	2.820	2.884	73.213	14.611
GEANT peak MiB	15.512	104.816	104.816	791.563	467.433

跨 batch 1/8/32，ARI 的 median latency 与 peak allocated memory 分别为 CalibTM 的 11.17× – 35.12× 和 5.75× – 12.58×；ImputeFormer adapter 分别为 1.81× – 10.68× 和 1.74× – 5.33×。与此同时，Linear 比 CalibTM 快 8.21× – 13.91×，Context-Free 也略快且显存相同。正确结论是 CalibTM 位于 deterministic Linear 和大型 learned models 之间，而不是“同时最准且最低成本”。

在同一 Intel Xeon Gold 6530 的未编译 FP32 checked pipelines 上，单线程 batch=1 的 CalibTM latency 为 4.78/17.26 ms（A/G）；ARI 为其 283.8×/186.9×，ImputeFormer adapter 为 37.2×/27.9×。batch=32、8 threads 时 CalibTM 达 561.5/146.7 windows/s，分别为 ARI 的 174.0×/116.7× 和 adapter 的 86.2×/30.9×。Linear 仍更便宜：单窗口快 16.3×/22.9×，吞吐高 18.1×/24.3×。计时排除模型加载与输入构造；这些仍是 seed-1 synthetic shapes 的 pipeline results，不是官方或 architecture-only runtime。

H800 batch=8：accuracy – latency（越左、越上越好）




图 3 A/G exact historical all-mask accuracy 与 seed-1 H800 batch=8 latency 的联合视图。两个轴来自不同但冻结的实验；ImputeFormer timing 含 adapter pipeline overhead，不能解释为架构内禀速度。

7 讨论

7.1 场景限定的设计原则

实验表明，当前 bounded instantiation 在每条 flow 只有三个锚点时构成一个小幅而可复现的 accuracy – efficiency operating point。Matched context-free control 识别了向 MLP 暴露 scaffold-derived 通道的增量作用；BRAIN confirmation 则表明该 operating point 能延伸到第三个 WAN。它们没有识别 boundedness、区域分解或 Linear scaffold 的因果必要性，也没有构成“低自由度必然优于自由重建”的普遍检验；ARI 和 ImputeFormer 在 Abilene 的优势正好说明高容量模型仍可能在特定网络占优。

7.2 与 ARI-LLM 的方法区别

ARI-LLM 的主路径是 dense flow vector → Flow2Vec/LSTM → LLM flow-token mixing → 五阶段 rollout。CalibTM 则采用 observation-only Linear → bounded local operator → hard copy 的单次前向路径。两者是不同的补全主干和信息—成本 operating point，CalibTM 并不依赖 ARI 输出。

7.3 新颖性边界

从数学实现看，CalibTM 是 canonical Linear 与小型有界校准网络的组合。它与已有 neural interpolation、prior-guided imputation 的差异不在 MLP，而在精确的任务参数化：锚点最终 hard-copy、内部/边界分区、尺度归一的有界形变，以及不使用可识别 flow 关系的单次前向算子。Matched context-free control 和成本曲线进一步说明该 operating point 在当前设置中具有实证价值。相较已经覆盖简单张量补全的 WTTC-TS、连续函数补全的 ImputeINR 和概率过程建模的 Utimac，本文保持更窄的 deterministic local calibration 定位。

7.4 局限

1. 三个 WAN 的主 masks 都是 artificial thinning，没有 native measured TM trace；BRAIN 还是 transductive-schema、LP-inverted OD，confirmation 仅约一天。
2. ARI/ImputeFormer 在 A/G 强烈异质且 BRAIN 无对应结果；H800/CPU 效率也只能解释为各自 checked pipelines，而非架构内禀速度。
3. 没有 matched unbounded/direct arm；edge 只是 distance-invariant segment shift，`vbar_f` 又带来 window-composition dependence，冻结 intervention 也不证明 two-head 重训非劣。

4. cross-WAN transfer 使用已消费 target 与 target-frozen preprocessing, 只是 descriptive evidence ; 方法限于 offline bidirectional repair, 且没有 uncertainty/abstention 输出。

8 结论

本文提出 CalibTM, 一个 5,475 参数的锚点保持有界插值校准器。它用低自由度的一次前向算子整体替换 ARI-LLM 的 LLM 与自回归主干。在 Abilene、GEANT 和冻结 SNDlib BRAIN confirmation 上, CalibTM 相对 canonical Linear 与同参数 context-free calibration 取得小而一致的 structured NMAE 改善; 冻结诊断把可测收益定位到 internal pointwise 与 boundary-segment offsets, 并表明其幅度界和非负投影实际参与推理。大型 learned baseline 的准确率具有明显网络依赖, 而 CalibTM 形成介于 Linear 与这些模型之间的 accuracy – efficiency operating point。

综合这些结果, 在极端人工时间稀疏、锚点可信、允许离线双向修复且不使用 topology/routing 的条件下, 先固定一个可行插值 scaffold、再学习小幅区域校准, 是一种有竞争力的设计选择。该结论限定于本文的信息与评估边界; 真实 missing process、direct-OD 外部数据和可信不确定性仍是后续工作。

参考文献

- [1] F. Yan, K. Jiang, Y. Qiao, M. Li, Y. Li, P. Yu, and C. Feng. ARI-LLM: Autoregressive Imputation for Network Traffic Matrix via Large Language Models. IEEE INFOCOM, pp. 1 – 10, 2026. DOI: 10.1109/INFOCOM59046.2026.11571176.
- [2] T. Nie et al. ImputeFormer: Low Rankness-Induced Transformers for Generalizable Spatiotemporal Imputation. ACM KDD, pp. 2260 – 2271, 2024. DOI: 10.1145/3637528.3671751.
- [3] X. Yuan et al. Diffusion Models Meet Network Management: Improving Traffic Matrix Analysis with Diffusion-based Approach. IEEE Transactions on Network and Service Management, 22(2):1259 – 1275, 2025. DOI: 10.1109/TNSM.2025.3527442.
- [4] M. Li et al. 3DDPS: A Traffic Matrix Estimation Method Based on Three-Dimensional Diffusion Posterior Sampling. Computer Networks, 257:111007, 2025. DOI: 10.1016/j.comnet.2024.111007.
- [5] T. Miyata. Traffic Matrix Completion by Weighted Tensor Nuclear Norm Minimization and Time Slicing. NOLTA, 15(2):311 – 323, 2024. DOI: 10.1587/nolta.15.311.
- [6] T. Miyata. Completion of Traffic Matrix by Tensor Nuclear Norm Minus Frobenius Norm Minimization and Time Slicing. IEEE/IFIP NOMS, pp. 1 – 5, 2024. DOI: 10.1109/NOMS59830.2024.10575433.
- [7] K. Xie et al. Neural Tensor Completion for Accurate Network Monitoring. IEEE INFOCOM, pp. 1688 – 1697, 2020. DOI: 10.1109/INFOCOM41043.2020.9155366.
- [8] K. Xie et al. Deep Adversarial Tensor Completion for Accurate Network Traffic Measurement. IEEE/ACM Transactions on Networking, 31(5):2101 – 2116, 2023. DOI: 10.1109/TNET.2022.3233908.
- [9] H. Wang et al. PeTTC: Pairwise Joint Embedding Based Contrastive Tensor Completion for Network Traffic Monitoring Services. IEEE Transactions on Services Computing, 18(1):357 – 371, 2025. DOI: 10.1109/TSC.2024.3517331.
- [10] F. N. Fritsch and R. E. Carlson. Monotone Piecewise Cubic Interpolation. SIAM Journal on Numerical Analysis, 17(2):238 – 246, 1980. DOI: 10.1137/0717021.
- [11] S. Somnugpong, N. Butploy, and K. Khiewwan. Percentile-Based Slope-Constrained Linear Interpolation for Robust Imputation of Highly Volatile PM2.5 Time Series. MethodsX, 16:103859, 2026. DOI: 10.1016/j.mex.2026.103859.
- [12] T. Niedzielski and M. Halicki. Improving Linear Interpolation of Missing Hydrological Data by Applying Integrated Autoregressive Models. Water Resources Management, 37(14):5707 – 5724, 2023. DOI: 10.1007/s11269-023-03625-7.
- [13] P. Yuan, Y. Jiao, J. Li, and Y. Xia. A Densely Connected Causal Convolutional Network Separating Past and Future Data for Filling Missing PM2.5 Time Series Data. Heliyon, 10(2):e24738, 2024. DOI: 10.1016/j.heliyon.2024.e24738.
- [14] S. N. Shukla and B. M. Marlin. Interpolation-Prediction Networks for Irregularly Sampled Time Series. ICLR, 2019.
- [15] M. Liu, H. Huang, H. Feng, L. Sun, B. Du, and Y. Fu. PriSTI: A Conditional Diffusion Framework for Spatiotemporal Imputation. IEEE ICDE, pp. 1927 – 1939, 2023. DOI: 10.1109/ICDE55515.2023.00150.
- [16] Z. Liu, X. Zhao, and Y. Song. RDPI: A Refine Diffusion Probability Generation Method for Spatiotemporal Data Imputation. AAAI, 39(12):12255 – 12263, 2025. DOI: 10.1609/aaai.v39i12.33335.
- [17] M. Li, K. Liu, J. Guo, J. Bu, H. Wang, and H. Wang. ImputeINR: Time Series Imputation via Implicit Neural Representations for Disease Diagnosis with Missing Data. IJCAI, pp. 9241 – 9249, 2025. DOI: 10.24963/ijcai.2025/1027.
- [18] X. Liu et al. Rethinking Traffic Matrix Completion: Estimate the Process, Not the Entries. arXiv:2605.02225, 2026.
- [19] X. Zeng et al. INT-MC: Low-Overhead In-Band Network-Wide Telemetry Based on Matrix Completion. Proc. ACM Meas. Anal. Comput. Syst., 8(3), Article 37, pp. 1 – 30, 2024. DOI: 10.1145/3700433.
- [20] S. Uhlig, B. Quoitin, J. Lepropre, and S. Balon. Providing Public Intradomain Traffic Matrices to the Research Community. ACM SIGCOMM Computer Communication Review, 36(1):83 – 86, 2006. DOI: 10.1145/1111322.1111341.
- [21] S. Orłowski, R. Wessäly, M. Pióro, and A. Tomaszewski. SNDlib 1.0—Survivable Network Design Library. Networks, 55(3):276 – 286, 2010. DOI: 10.1002/net.20371.