

融合时空上下文与观测直读的网络流量矩阵补全

作者信息待填写

中文内部研究初稿 2026 年 9 月 16 日

摘要—稀疏网络流量矩阵补全需要同时利用相关流的时空信息与本流的邻近真实观测。本文构建一个从头联合训练的融合模型：采用一层 SPIN 时空编码，并行读取本流前后最近观测，在此基础上加入仅由可见源写入的双向同步矩阵记忆。通过与去记忆变体的配对比较，研究额外记忆是否值得保留。在 Abilene 与处理后的 GEANT 快照上，固定 20% 观测率、三种缺失条件和两个初始化，共完成八条 120 轮训练轨迹。开发集结果表明，加入记忆后，归一化平均绝对误差在 Abilene 基本持平，在 GEANT 增加 1.41%；归一化均方根误差分别降低 0.86% 和 1.24%。同一 H20 上的完整推理测量显示，记忆使批量为 8 时的每窗摊销耗时增加约 62%–64%。去记忆模型相对既有四层 SPIN 参考的归一化平均绝对误差分别降低 1.22% 和 0.74%，对应批量推理耗时约为参考的 27.2% 和 26.7%。这些结果支持优先研究较简化的时空上下文与观测直读组合，并将同步记忆的价值限定为平方误差与计算成本的取舍。本文结果属于开发性比较，尚需在预先固定的最终评估中确认。

关键词—网络流量矩阵，稀疏观测，时空补全，观测直读，同步矩阵记忆

I. 引言与相关工作

网络流量矩阵描述一组源宿对在各时刻的流量。当测量资源受限、部分监测不可用或观测在流间分配不均时，补全器需要从有限可见值恢复缺失项。同一条流的邻近观测通常提供直接的幅度和变化线索，相关流的可见数据则可能补充本流在较长缺口中的信息。如何组合这两类信息，并判断新增结构是否值得其计算成本，是本文的研究问题。

已有方法已广泛利用时空关系。SPIN 通过面向稀疏观测的时空信息传播，为目标位置构造可解码表示 [1]。它本身能够读取本流与邻流的时间信息，因此不能把引入另一条记忆路径解释为首次为该编码器增加时间依赖。网络流量矩阵研究中的 SRMF 及其局部补正也表明，较大范围估计与邻近真实观测相结合具有直接先例 [2]。本文采用局部观测直读的具体共享神经读出实现，不将全局与局部结合这一思想本身作为新颖性主张。

另一类相关结构是以矩阵状态存储键值关联的记忆。Delta 规则根据当前键的预测残差修正状态，DeltaNet 研究了这一类更新及其高效训练 [3]。本文沿用项目中的同步桶更新实现：同一时刻的可见邻流从同一个旧状态计算修正，以避免同桶流输入顺序直接决定更新结果。这里不复用 DeltaNet 的语言建模实验结论，也没有实现其整套序列并行训练算法；本文关注的是矩阵记忆作为流量补全分支时的实际价值。

我们构建共享上下文与解码接口的两个变体。完整变体 SPIN-Direct-Sync 将一层 SPIN 生成的上下文投影为记忆键、值和查询，同时通过 Direct 路径读取本流前后各两个最近的真实观测。去记忆变体 SPIN-Direct 保留上下文、Direct、查询与解码器，删除 K/V 和扫描。两者全部参数从头共同训练，共有参数在同一初始化种子下取相同初值，以较小的实验范围回答额外记忆是否提供可重复增量。

本文的具体工作包括：一是给出可见信息约束下的联合读出实现及可对应的去记忆变体；二是在两套 WAN 快

照、三种固定预算缺失条件和两个初始化下完整报告误差取舍；三是在同一设备上测量包含编码、读出及输入输出处理的推理成本。结果使后续候选收窄到较简单的 SPIN-Direct，而 SPIN-Direct-Sync 在平方误差指标上的收益及代价也被保留。本文是一项开发性结构研究，目标是形成可复核的下一步判断，并不宣称所有组成分支已被证明必要或当前方案普遍领先。

II. 方法

A. 任务与上下文编码

本文考察已有组件在统一补全网络中的组合：采用 SPIN 的观测掩蔽时空编码 [1]，结合本流直接读出及基于 delta-rule 残差纠错思想的矩阵记忆 [3]。完整模型记为 SPIN-Direct-Sync。

设窗口为 $X \in \mathbb{R}_{\geq 0}^{T \times F}$ ， $M_{ti} = 1$ 表示可见， $T = 50$ 。任务是离线整窗补全：允许使用窗口内前后两侧观测。全局均值 μ 、总体标准差 σ 及邻域均由拟合段确定；每流邻域包含自身，以及按拟合段 Pearson 相关降序选择的至多八个正相关邻流。隐藏真值不进入编码，标准化输入为

$$z_{ti} = \begin{cases} (X_{ti} - \mu)/\sigma, & M_{ti} = 1, \\ 0, & M_{ti} = 0. \end{cases} \quad (1)$$

槽位 $t/49$ 、可学习流嵌入与正弦位置编码产生 32 维位置表示 p_{ti} 。可见位置叠加数值编码，经归一化和数值跳连后进入一层 32 维 SPIN 时空块，得到 h_{ti} 。该块同时聚合本流跨时间观测和邻流时空观测，并非只处理空间关系；空间分支逐邻流在源时间维归一化后求和。所有流共同编码，缺失位置也可作为查询，但仅可见位置作为注意力源。时间分支屏蔽自身时间对角项，空间分支排除自身流；无有效观测源时注意力读出为零，根节点跳连保留查询位置表示。上下文可依赖整窗，因此后续扫描方向不构成因果保证。

这一结构不同于原四层 SPIN 网络：仅使用一次上下文编码和最终输出监督，不沿用原模型的多层读出深监督。因此，与原 SPIN 的结构差异不能单独归因于 Sync。

B. Direct 双向局部读出

对目标 (t, i) ，分别在 $s \leq t$ 与 $s \geq t$ 的本流可见位置中，按槽位距离选择最近的至多两个，记为 $S_{ti}^{\rightarrow}$ 与 $S_{ti}^{\leftarrow}$ 。可见查询自身允许进入两侧集合。两方向共享两个带偏置的 16 维仿射投影 ϕ_Q^D, ϕ_K^D ，以位置表示打分：

$$\ell_{tis} = \frac{\phi_Q^D(p_{ti})^\top \phi_K^D(p_{si})}{\sqrt{16}} - \log(1 + |t - s|). \quad (2)$$

各集合内的 softmax 权重用于汇总可见标准化数值及归一化距离 $|t - s|/49$ ，再与支持是否存在的指示量组成三维特征，经无偏置投影得到 128 维读出 $d_{ti}^{\rightarrow}, d_{ti}^{\leftarrow}$ 。空集合读出




图 1. 联合模型的可见信息路径。SPIN 与 Direct 使用同一窗口的可见输入；Direct 读取原始观测值，不读取 SPIN 的隐表示。完整变体在两个方向内分别将 Direct 读出与 Sync 记忆读出相加，再与上下文查询拼接解码。去记忆变体删除 K/V 与扫描，保留其余路径。整窗上下文使本模型属于离线补全。

为零。Direct 的权重来自 p ，读出的数值来自真实观测，并不读取 SPIN 的补全预测。

C. Sync 同步矩阵记忆

上下文 h 另行生成键、值与查询，分为四个 32 维头，键和查询在头内作 ℓ_2 归一化。每个目标、方向及头维护独立的 32×32 状态。对同一槽位的自身与邻流，仅可见源保留键值；隐藏源和无效邻域槽的键值均置零。省略目标和头下标，堆叠 $K_t, V_t \in \mathbb{R}^{J \times 32}$ ，同步更新为

$$c_t = \max\{1, \|K_t K_t^\top\|_\infty\},$$

$$S_{\text{new}} = S_{\text{old}} + \frac{(V_t^\top - S_{\text{old}} K_t^\top) K_t}{c_t}. \quad (3)$$

其中矩阵无穷范数为最大绝对行和。所有同刻源均相对同一旧状态计算残差后一次写入，不依赖桶内逐源写入顺序；空桶不改变状态。两方向共享投影，独立从零状态正反扫描，每个新窗口重置。当前桶全部写入后，以 $S_{\text{new}q_{ti}}$ 读取，拼接四头得到 128 维记忆读出 $m_{ti}^{\rightarrow}, m_{ti}^{\leftarrow}$ 。写入值是可见源的上下文特征，不是将补全值当作新观测。

D. 统一解码与去记忆对照

每个方向将 Direct 与记忆以系数 1:1 相加，再拼接 128 维上下文查询 q_{ti} ，由共享 $384 \rightarrow 128 \rightarrow 1$ 的 GELU 解码器 D 输出：

$$R_{ti} = \mu + \sigma D([m_{ti}^{\rightarrow} + d_{ti}^{\rightarrow}; m_{ti}^{\leftarrow} + d_{ti}^{\leftarrow}; q_{ti}]). \quad (4)$$

相加系数不代表两路径贡献各占一半。最终仅对缺失位置作非负截断，可见位置回填原值。所有模块从头联合训练，末层零初始化；对批次缺失集合 Ω 优化未截断、原量纲的 L1 损失：

$$\mathcal{L} = \frac{1}{C|\Omega|} \sum_{(b,t,i) \in \Omega} |R_{bti} - X_{bti}|, \quad C = \text{mean } |X_{\text{fit}}|. \quad (5)$$

非负截断与观测回填不参与损失计算；优化设置见实验部分。

去 Sync 模型 SPIN-Direct 删除键值模块及矩阵扫描，令两向 $m = 0$ ，保留同一 SPIN 块、Direct、上下文查询和

解码器。故去除记忆后仍有 SPIN 上下文经查询进入预测。两模型同种子的共有参数初值一致，分别训练；其参数量不同，该对照用于考察加入当前 Sync 路径的作用，不是等参数量比较。

III. 实验设置

A. 数据与评价范围

采用 Abilene 的 144 条流和 GEANT 处理快照的 462 条流。Abilene 使用公开的 X01-X24 记录 [4]；GEANT 使用 ARI-LLM 发布仓库中固定版本的 10,772 行 CSV [5]。后者被作为确定的处理后数组使用，不将其行号直接换算为原生时间戳或物理单位。

窗口长度为 50 槽。以零起始、左闭右开的行区间表示，Abilene 的拟合范围为 $[0, 33335)$ ，开发范围为 $[33384, 37484)$ ；GEANT 相应为 $[0, 7023)$ 和 $[7072, 8322)$ 。每套数据在拟合范围内按等间隔起点取 512 个固定窗口；GEANT 拟合窗口存在重叠。开发窗口互不重叠，分别为 82 和 25 个。选定的 512 个拟合窗口用于监督训练，完整拟合段用于统计量和相关邻流图的构造，当前补全窗口的模型输入只包含可见值和掩码。这是假设具有离线完整历史数据的监督补全设置。

所有结果均来自开发范围；该范围用于检查点选择，不能视作独立最终测试。历史后续范围也曾被同一项目的早前研究使用，因此本文仅报告开发性结果。

B. 三种固定预算缺失条件

三种条件都严格保留窗口内 20% 的数值。均匀条件中每条流随机保留 10/50 个位置；不均匀条件中，随机选取一半流各保留 4 个位置，其余流各保留 16 个位置。共享缺口条件沿用这一流间预算，为一半流设置共同的连续 10 槽不可见区间，并在其余位置重新分配观测，保持每条流的观测数量不变。未受影响流与不均匀条件使用相同观测位置。因此条件差异来自观测分配和时间形状，不来自总观测测量增加。

C. 训练、消融与参考

两 WAN、两变体和种子 41001/41002 构成八条轨迹。采用 AdamW，学习率 10^{-3} 、权重衰减 10^{-4} 、梯度范数上

表 I
开发集三条件平均误差；越低越好。新变体为两个初始化的均值 $\pm$ 样本标准差。旧可训练参考各一个检查点；训练配方不同。

方法	Abilene		GEANT	
	NMAE	NRMSE	NMAE	NRMSE
SPIN-Direct-Sync	0.162431 $\pm$ 0.000771	0.218068 $\pm$ 0.000153	0.169420 $\pm$ 0.001018	0.228322 $\pm$ 0.000202
SPIN-Direct	0.162369 $\pm$ 0.001505	0.219958 $\pm$ 0.000469	0.167071 $\pm$ 0.000856	0.231189 $\pm$ 0.001893
旧 SPIN 参考	0.164380	0.220773	0.168317	0.229492
旧 Direct+Sync 参考	0.165639	0.223398	0.173336	0.228001
Linear	0.171021	0.241480	0.167739	0.228767

表 II
同一 H20 上的完整推理成本。B1 为单窗整批耗时；B8 为批量 8 的摊销每窗耗时。峰值为 B8 的 PyTorch 已分配显存，非整卡占用。

WAN	模型	参数量	B1 (ms)	B8 (ms/窗)	B8 峰值 (MiB)
Abilene	SPIN-Direct-Sync	98,693	42.879	10.060	2896.948
Abilene	SPIN-Direct	73,733	9.448	6.117	2896.853
Abilene	旧 SPIN	65,364	27.388	22.494	2897.615
Abilene	旧 Direct+Sync	79,137	37.015	4.767	1219.579
GEANT	SPIN-Direct-Sync	108,869	53.023	30.849	3797.136
GEANT	SPIN-Direct	83,909	22.422	19.017	2976.750
GEANT	旧 SPIN	95,892	79.850	71.355	2979.620
GEANT	旧 Direct+Sync	84,225	37.186	12.253	3830.259

限 1、批量 8，不使用学习率调度；全部目标流参与计算，FP32 且关闭 TF32。训练掩码和窗口顺序按轮刷新，三条件近似均衡分配；同种子配对共享这些输入及共有参数初值。训练掩码、顺序和开发掩码的固定种子分别为 61001、51001 和 71001。

初始轨迹采用早停，随后在已见开发结果后决定导入同一轨迹的模型、优化器和随机状态，接续到总计 120 轮。该固定轮数比较是训练时长诊断，早停阶段与接续阶段只算一次训练，不能充当额外独立重复。所有变体沿用同一总轮数，以三条件平均开发 NMAE 最小的检查点作为结果。

唯一训练消融为去 Sync，不增加门控、宽度或损失搜索。参考包含既有四层 SPIN、未加入 SPIN 上下文的既有 Direct+Sync，以及逐流线性插值。线性插值使用可见位置，边缘取端点值，无观测时取拟合期流均值。旧可训练参考各只保留一个初始化结果，且训练配方与新模型不同：旧 SPIN 的上限为 300 轮，在 Abilene/GEANT 分别训练 137/300 轮；旧 Direct+Sync 分别训练 53/71 轮，上限 120 轮。这些结果用于完整系统比较，不作为同预算组件归因。

D. 指标与完整推理测量

对每个条件，先合并该开发范围全部缺失位置 Ω ，计算

$$\begin{aligned} \text{NMAE} &= \frac{\sum_{\Omega} |\hat{x} - x|}{\sum_{\Omega} |x|}, \\ \text{NRMSE} &= \sqrt{\frac{\sum_{\Omega} (\hat{x} - x)^2}{\sum_{\Omega} x^2}}. \end{aligned} \quad (6)$$

然后对三条件等权取平均。NMAE 始终为主要指标；NRMSE 对较大误差更敏感，用于解释取舍。新模型跨两个种子报告均值和样本标准差，不据此构造显著性结论。

完整推理在同一 NVIDIA H20 上逐模型运行，采用 FP32、关闭 TF32，对两个数据集各自的前 8 个拟合窗口测试批量 1 和 8。新两变体与旧 SPIN 的内部节点分块为 32，旧 Direct+Sync 沿用自身实现。四种模型均使用 seed41001 的最佳检查点；每个条件、批量和模型进行 5 次热身与 15 次计时。计时包含输入传输、全流预测、输出回传、有限值检查、非负截断和观测值回填，不包含权重加载、拟合统计量及图准备、掩码生成。表中批量 1 耗时为三条件各自整批中位数的平均，批量 8 耗时再除以 8，表示摊销每窗耗时。显存为批量 8 三条件中的最大 PyTorch 已分配值，含当前常驻模型与共享统计量，不等于整卡占用。此过程只测成本，没有计算新准确率分数。

IV. 结果与讨论

A. 额外同步记忆带来的误差取舍

表 I 汇总两个种子的完整结果。相对 SPIN-Direct，SPIN-Direct-Sync 的平均 NMAE 在 Abilene 增加 0.0382%，差异很小；其中第一个种子改善 0.2795%，第二个种子反而恶化 0.3601%，不能由单个获胜种子推出稳定增量。在 GEANT 上，SPIN-Direct-Sync 的平均 NMAE 增加 1.4063%；两个种子的增加分别为 0.6109% 和 2.2074%，且两个种子下的三个条件都具有相同方向。因此，在当前主要指标与预算下，新增记忆没有获得默认保留的必要性证据。

平方误差指标呈现另一面。SPIN-Direct-Sync 相对 SPIN-Direct 的平均 NRMSE 在 Abilene 降低 0.8592%，在 GEANT 降低 1.2402%，四个配对的三条件平均 NRMSE 均改善。不过，Abilene 第二个种子的“不均匀”条件仍有小幅退化，因此不能扩大成所有种子、所有条件和所有指标均改善。现有数据支持增加记忆改变了误差取舍，而不支持把次要指标的改善替换成主要指标获胜的结论。

SPIN 上下文已经聚合整窗可见的时空信息，Direct 又提供了近邻原值的短路径，因而记忆与已有读出可能存在职

责重叠。但这只是解释候选。Sync 读取邻流上下文还可能带来间接邻域信息，且具有不同的矩阵压缩与查询机制。本轮实验不能区分信息重叠、优化难度和任务中剩余可利用信号不足等原因，不将当前消融结果解释为已定位某个失败机制。

B. 与已有参考的系统比较

SPIN-Direct 相对旧 SPIN 的平均 NMAE 在 Abilene 降低 1.2235%，在 GEANT 降低 0.7406%。其 NRMSE 在 Abilene 降低 0.3688%，在 GEANT 却增加 0.7397%。相对 Linear，SPIN-Direct 的平均 NMAE 分别降低 5.0593% 和 0.3983%，但 GEANT 上的 NRMSE 增加 1.0591%。这说明更简化的组合具备开发 NMAE 竞争力，同时仍存在平方误差代价。

SPIN-Direct-Sync 在 Abilene 的平均 NMAE 与 NRMSE 都低于旧 SPIN；在 GEANT，其 NMAE 高于旧 SPIN 0.6553%，NRMSE 则低 0.5096%。旧 Direct+Sync 在 GEANT 上保留了更低的平均 NRMSE，Linear 也仍是接近主要神经模型的简单参考。不同参考在绝对误差、平方误差和成本上形成不同取舍。由于参考模型的深度、优化和检查点选择轨迹不同，这些比较尚不能把差异全部归因于 Direct 或某个特定更新规则。

C. 推理成本与后续模型选择

表II显示，SPIN-Direct-Sync 相对 SPIN-Direct 的单窗耗时比为 4.54 和 2.36，批量 8 时的摊销耗时分别增加 64.44% 和 62.22%。同步记忆的参数增加量固定为 24,960，但参数数量不足以描述两方向扫描及中间张量带来的执行成本。GEANT 的批量 8 峰值已分配显存增加约 27.56%；Abilene 的对应峰值几乎不变，与共享上下文临时张量占主导的解释一致，但当前测量没有逐算子定位峰值来源。

SPIN-Direct 的批量 8 摊销耗时约为旧 SPIN 的 27.20% 和 26.65%，由同批量耗时折算，批量推理速度分别约为旧 SPIN 的 3.68 和 3.75 倍。该优势伴随着一层与四层上下文的结构差异，不能单独归因于 Direct。它也不意味着所有资源都降低：Abilene 的参数数量比旧 SPIN 更多，两个 WAN 上的峰值显存均仅有极小变化。既有 Direct+Sync 在批量 8 的两个 WAN 上仍比 SPIN-Direct 更快；Linear 没有参加本轮成本测量，不能据此声称在全部参考中成本最优。

综合预定 NMAE、推理耗时和结构复杂度，SPIN-Direct 是本轮之后更合理的优先简化候选。若应用更看重平方误差，SPIN-Direct-Sync 的结果提供了一个额外成本换取 NRMSE 改善的实现选择，但当前证据没有建立这种取舍在独立最终评价上的稳定性。模型选择应保留任务指标和部署批量，不能只依据参数量或某个获胜数字。

V. 局限与下一步

当前结果回答的是固定实现和训练预算下的结构取舍。两种初始化中的一致方向具有描述价值，但不能替代更多独立训练或构成统计显著性证据。八条轨迹中七条的最佳轮位于 113–120 轮，说明部分模型仍可能受训练预算影响；达到 120 轮不能被解释为已充分优化，也不能据此认定同步记忆机制普遍无效。本轮保持结构、融合方式和损失固定，以既定预算作为比较边界。

更直接的限制来自评价用途。开发集既用于检查点选择，也参与了既有研究的模型选择；项目中的后续数据范围同

样曾被历史实验访问。因此，本轮缺少与开发选型隔离的独立最终测试。两个 WAN、单一观测预算与固定窗口长度也不能支持对其他网络、时间跨度或缺失机制的普遍结论。GEANT 处理快照尚缺少到原生时间戳和物理单位的核实映射，所以本文仅以行或槽位表述距离，不据此解释具体分钟尺度上的网络行为。

关于方法归因，去 Sync 同时删除了 24,960 个参数及相应变换，现有实验识别的是整个新增记忆分支的作用。它没有分离同步规则、参数容量和有效邻域范围的贡献，也没有单独证明 Direct 相对相同一层 SPIN 模型的独立增量。旧四层 SPIN 参考的结构与训练日程均不同，不能代替这一组件归因。本文据此将后续方向收窄到 SPIN-Direct 的精度与推理成本取舍，保留 SPIN-Direct-Sync 的完整结果，不把组合已有模块本身视为首次提出的概念。

后续若继续推进投稿，优先补足支持所选主张的最小证据：在相同一层上下文与训练设置下确认 Direct 读出的增量，并在事先固定、可与选型区分的最终评估来源上确认排序。这两项针对现有主张的不足，不意味着需要增加观测率、门控和新模块的实验矩阵。当前版本先作为组织方法、结果和局限的内部初稿。

VI. 结论

本文联合训练一层 SPIN 时空上下文、局部真实观测直读和可选的双向同步矩阵记忆，以两套 WAN 数据上的八条配对轨迹及统一推理测量检验额外记忆的价值。在固定 120 轮的开发评估中，Sync 没有带来稳定的主指标 NMAE 改善，但四个配对的条件平均 NRMSE 均有改善，并付出额外推理成本。较简化的 SPIN-Direct 在两个 WAN 上取得有竞争力的开发 NMAE 及相对旧 SPIN 参考的速度优势，适合作为下一阶段的优先候选。这些结论保留了误差指标之间的取舍，也保留了参考配方不同、开发选型和组件归因的限制。

参考文献

- [1] I. Marisca, A. Cini, and C. Alippi, “Learning to reconstruct missing data from spatiotemporal graphs with sparse observations,” in *Advances in Neural Information Processing Systems*, vol. 35. Curran Associates, Inc., 2022, pp. 32 069–32 082. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2022/file/cf70320e93c08b39b1b29a348097a376-Paper-Conference.pdf
- [2] Y. Zhang, M. Roughan, W. Willinger, and L. Qiu, “Spatio-temporal compressive sensing and internet traffic matrices,” in *Proceedings of the ACM SIGCOMM 2009 Conference on Data Communication*, 2009, pp. 267–278. [Online]. Available: <https://www.cs.utexas.edu/~yzhang/papers/sensing-sigc09.pdf>
- [3] S. Yang, B. Wang, Y. Zhang, Y. Shen, and Y. Kim, “Parallelizing linear transformers with the delta rule over sequence length,” in *Advances in Neural Information Processing Systems*, vol. 37, 2024, pp. 115 491–115 522. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2024/hash/d13a3eae72366e61dfdc7eea82eeb685-Abstract-Conference.html
- [4] “Abilene traffic matrix data: Format documentation,” traffic weeks X01–X24 from 2004; accessed September 16, 2026. [Online]. Available: <https://www.cs.utexas.edu/~yzhang/research/AbileneTM/readme.txt>
- [5] “ARI-LLM: Source code and released datasets,” GitHub repository, pinned commit 6a4f63656dbf; accessed September 16, 2026. [Online]. Available: https://github.com/shuzi1024/ARI-LLM/blob/6a4f63656dbf0964219c516ffd3e1e8fcf99ebd/datasets/net_traffic/GEANT/geant.csv